Badanie korelacji mocy a przełożenia tylnego mostu w samochodach osobowych

Karol Bartnicki Inżynieria i Analiza Danych AGH

WPROWADZENIE

Moc silnika, mierzona w koniach mechanicznych (**hp** – horsepower), jest jedną z kluczowych cech podawanych przy porównywaniu różnych modeli i marek samochodów. Auta o większej mocy od zawsze budziły większe zainteresowanie, często kojarząc się z lepszymi osiągami i wyższą prędkością maksymalną. Jednak sama moc nie jest jedynym czynnikiem wpływającym na osiągi pojazdu – istotną rolę odgrywa również przełożenie tylnego mostu (**drat** – rear axle ratio), które wpływa na sposób, w jaki moc jest przekazywana na koła.

Celem tego projektu jest analiza zależności między mocą silnika a przełożeniem tylnego mostu, bazując na danych z pakietu „mtcars” przechowującej dane kilku popularnych modeli aut. Pozwoli to lepiej zrozumieć, jak te dwa parametry współgrają i jak wpływają na charakterystykę pojazdu.

PODSTAWY TEORETYCZNE

Zbiór danych „mtcars” w R jest wbudowana ramką danych, która zawiera informacje o 32 samochodach z lat 70-tych XX wieku. Zawiera 11 zmiennych opisujących różne cechy tych pojazdów. Oto szczegółowy opis tych zmiennych:

- mpg – zużycie paliwa, wyrażone w milach na galon (miles per galon).
- cyl – liczba cylindrów w silniku.
- Disp – pojemność silnika w calach sześciennych mechanicznych (horespower).
- Drat – współczynnik przekładni (rear axle ratio).
- Wt – waga samochodu, wyrażona w tysiącach funtów.
- Qsec – czas przejazdu ¼ mili, wyrażona w sekundach (quarter mile time).
- Vs – rodzaj silnika: 0 - oznacza silnik widlasty (V), 1 – silnik rzędowy.
- Am – rodzaj skrzyni biegów: 0 – oznacza automatyczną, 1 – manualną.
- Gear – liczba biegów w skrzyni biegów.
- Carb – liczba gaźników w samochodzie.

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4	108.0	93	3.85	2.320	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1
Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2
Valiant	18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1
Duster 360	14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4
Merc 240D	24.4	4	146.7	62	3.69	3.190	20.00	1	0	4	2

Rysunek 1 Kilka pierwszych wierszy zbioru danych mtcars

```
> data("mtcars")
```

Do obliczeń będziemy używać zmiennych:

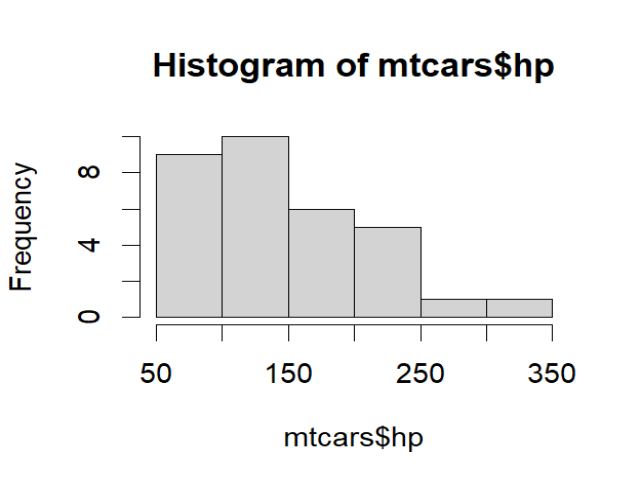

Rysunek 2 Histogram zmiennej hp z mtcars

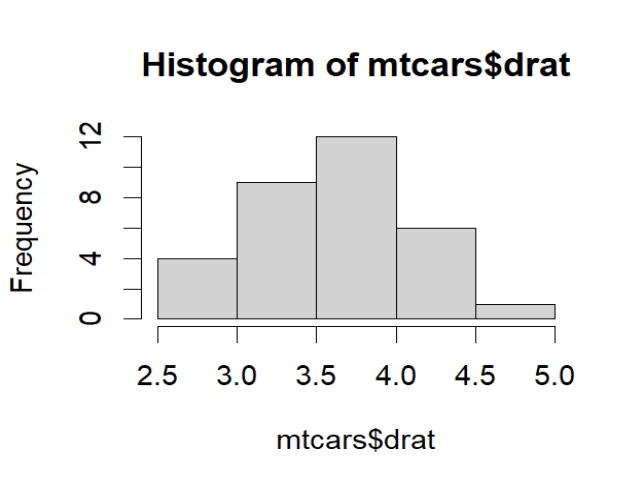

Rysunek 3 Histogram zmiennej drat z mtcars

```
> hist(mtcars$hp)
> hist(mtcars$drat)
```

Do obliczenia i przedstawienia danych statystycznych tej próbki danych użyję podstawowych funkcji z języka programowania R:

- mean() – oblicza średnią arytmetyczną podanej listy danych.
- median() – oblicza medianę, czyli wartość środkową uporządkowanego zbioru danych.
- min() – zwraca najmniejszą wartość w podanym zbiorze danych.
- max() – zwraca największą wartość w podanym zbiorze danych.
- sd() - oblicza odchylenie standardowe, czyli miarę rozproszenia danych względem śr.
- var() - oblicza wariancję, czyli miarę zmienności danych.
- IQR() - zwraca rozstęp, czyli różnicę między trzecim a pierwszym kwartylem (Q3 - Q1).
- shapiro.test() - przeprowadza test Shapiro-Wilka na normalność rozkładu danych.
- cor.test() - przeprowadza test korelacji między dwiema zmiennymi.
- hist() - rysuje histogram rozkładu danych.
- boxplot() - tworzy wykres pudełkowy.
- skewness() - oblicza skośność rozkładu, asymetrię rozkładu wartości względem średniej.
- heatmap() – tworzy heatmapę gdzie kolorem ilustruje wielkość wartości zmiennej.
- kurtosis() - oblicza kurtozę, czyli miarę spłaszczenia rozkładu. Z biblioteki „e1071”.
- corrplot() – tworzy wykres obrazujący siłę i kierunek korelacji. Z biblioteki „corrplot”.

CZĘŚĆ ANALITYCZNA

Rozproszenie obserwacji wokół średniej oraz ich intensywność:

```
> install.packages("e1071")
```

Instalujemy pakiet „e1071” potrzebny do użycia funkcji kurtosis(). Po użyciu funkcji otrzymujemy wartość kurtozy dla zmiennych „hp” oraz „drat”. Obie wartości są mniejsze od zera dzięki czemu możemy wywnioskować, że obie zmienne przyjmują ***rozkład platykurtyczny.*** Oznacza to, że intensywność wartości ekstremalnych jest mniejsza od rozkładu normalnego. Możemy zauważyć to na wykresie pudełkowym, objawi się to ***‘wąskimi ogonami’***.

```
> library(e1071)
> kurtosis(mtcars$hp)
[1] -0.1355511
> kurtosis(mtcars$drat)
[1] -0.7147006
```

```
> boxplot(mtcars$hp)
> boxplot(mtcars$drat)
```

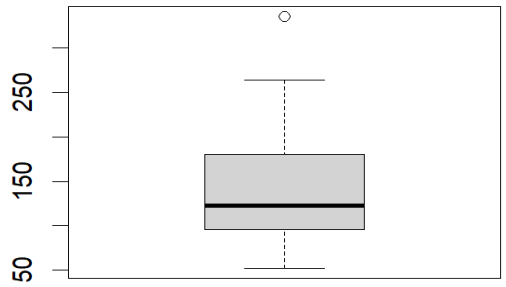

Rysunek 5 Wykres pudełkowy zmiennej hp

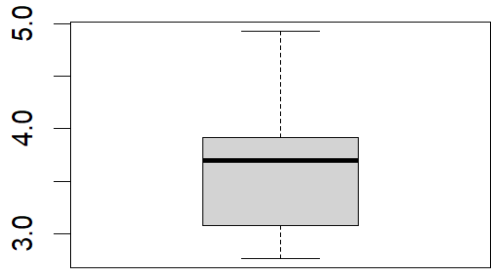

Rysunek 4 Wykres pudełkowy zmiennej drat

Występowanie obserwacji skrajnych oraz czy średnia rzeczywiście znajduje się w centrum analizowanego rozkładu, opis zmienności danych w zbiorze

```
> min(mtcars$hp)
[1] 52
> max(mtcars$hp)
[1] 335
> min(mtcars$drat)
[1] 2.76
> max(mtcars$drat)
[1] 4.93
```

Sprawdzamy wartości skrajne dla zmiennej hp oraz drat używając funkcji ***min()*** i ***max()*** do wyznaczenia wartości minimalnych i maksymalnych.

```
> skewness(mtcars$hp)
[1] 0.7260237
> skewness(mtcars$drat)
[1] 0.2659039
```

Używamy funkcji ***skewness()*** do obliczenia skośności, która wskazuje na rozbieżności pomiędzy wartością średnią a centrum danego rozkładu:

- hp – skośność jest wysoka, czyli średnia nie znajduje się w centrum rozkładu, czyli daleko mu do normalnego.
- drat – skośność dużo niższa, średnia znajduje się mniej więcej w centrum rozkładu, więc może on przypominać normalny.

Aby opisać zmienność danych w zbiorze posłużymy się:

- odchyleniem standardowym, które jest miarą rozproszenia wokół średniej - im zbiór danych jest bardziej zróżnicowany tym większe odchylenie standardowe.
- wariancją, która opisuje zróżnicowanie zbiorowości. Jest średnią arytmetyczną kwadratów odchyleń poszczególnych wartości cechy od średniej arytmetycznej zbiorowości.
- Rozstępem jako różnicą między największą a najmniejszą wartością w zbiorze.
- Rozstępem kwartylowym, który jest różnicą między kwartylem 3 a kwartylem 1.

```
> mean(mtcars$hp)
[1] 146.6875
> var(mtcars$hp)
[1] 4700.867
> sd(mtcars$hp)
[1] 68.56287
> median(mtcars$hp)
[1] 123
> max(mtcars$hp) - min(mtcars$hp)
[1] 283
> IQR(mtcars$hp)
[1] 83.5
```

Zmienna hp:

Otrzymane odchylenie standardowe przyrównujemy do średniej arytmetycznej tego zbioru. Wynosi ono 30-50% średniej co jest dużym wynikiem, więc ***wartości są daleko od średniej***. Rozstęp kwartylowy nie stanowi nawet 50% rozstępu, czyli jest niski. Oznacza to, że ***wartości są skupione wokół mediany***. Natomiast rozstęp jest dużo wyższy od średniej, co wskazuje na ***wartości odrastające***, które widać na *Rysunek 3*.

Zmienna drat:

Odchylenie standardowe, które otrzymaliśmy jest znacznie mniejsze od średniej arytmetycznej, czyli ***wartości są blisko średniej***. Rozstęp kwartylowy jest umiarkowanie niski względem rozstępu co oznacza, że ***dane są lekko rozproszone***. Sam rozstęp natomiast jest w miarę wysoki co wskazuje na ***szeroki zakres danych***.

```
> mean(mtcars$drat)
[1] 3.596563
> var(mtcars$drat)
[1] 0.2858814
> sd(mtcars$drat)
[1] 0.5346787
> median(mtcars$drat)
[1] 3.695
> max(mtcars$drat) - min(mtcars$drat)
[1] 2.17
> IQR(mtcars$drat)
[1] 0.84
```

Analiza Korelacji

Aby wybrać odpowiednie narzędzie do badania korelacji między zmiennymi musimy mieć pewność jaki mają one rozkład danych. Z dotychczasowej analizy wynika, że rozkład zmiennej hp znacznie różni się od rozkładu normalnego. Aby się upewnić użyjemy testu ***Shapiro-Wilka***, który jest standardowym narzędziem wykorzystywanym do sprawdzenia normalności danych, ze względu na wyróżniającą go dużą moc.

```
> shapiro.test(mtcars$hp)

        Shapiro-Wilk normality test

data:  mtcars$hp
W = 0.93342, p-value = 0.04881
```

Zmienna hp:

Wynik testu (wartość W) jest całkiem wysoka, jednak wartość p jest mniejsza od ustalonej wartości istotności wyniku (0.05). Jest to wystarczający dowód, że ***dane zmiennej nie charakteryzują się rozkładem normalnym***.

Zmienna drat:

W tym przypadku wynik jest bardzo wysoki tak samo jak wartość p, która jest większa od (0.05). Wskazuje to, że ***zmienna drat charakteryzuje się rozkładem normalnym***.

```
> shapiro.test(mtcars$drat)

        Shapiro-Wilk normality test

data:  mtcars$drat
W = 0.94588, p-value = 0.1101
```

W tej sytuacji należy użyć testu korelacji odpowiedniego dla danych bez rozkładu normalnego. Służy do tego test korelacji rang ***Spearmana***, stosowany w przypadku naruszenia założenia normalności. Wywołujemy go funkcją cor.test() z dodatkowym parametrem (method = 'spearman').

```
> cor.test(mtcars$hp, mtcars$drat, method = 'spearman', use='complete.obs')

        Spearman's rank correlation rho

data:  mtcars$hp and mtcars$drat
S = 8293.8, p-value = 0.002278
alternative hypothesis: true rho is not equal to 0
sample estimates:
      rho
-0.520125
```

W wyniku istotna jest wartość p (p-value) oraz ostateczny wynik na samym dole. Parametr p to wysokość prawdopodobieństwa, że korelacja między danymi wystąpiła przypadkowo – ***hipoteza zerowa***.

Interpretacja wyników:

Wartość prawdopodobieństwa p jest poniżej ustalonej wartości (0.05) co oznacza, że nie jest ona istotna i można odrzucić hipotezę zerową.

Wynik główny mieści się w przedziale (0.5-1) (w tym kryterium nie zwracamy uwagi na znak) co oznacza, że ***związek między danymi jest silny***. Natomiast fakt, że jest to liczba ujemna oznacza kierunek korelacji. Dla korelacji ujemnej wzrost wartości jednej cechy towarzyszy spadkowi średnich wartości drugiej cechy. W naszym przypadku zwiększająca się moc (hp) związana jest z maleniem przełożenia przekładni (drat).

WYNIKI

Zobrazowanie wyników przeprowadzonej analizy oraz wzajemnej korelacji zmiennych hp i drat.

```
> install.packages("corrplot")
> library(corrplot)
corrplot 0.95 loaded
> mtcars_hp_drat = data.frame(mtcars$hp, mtcars$drat)
> colnames(mtcars_hp_drat) = c("hp", "drat")
> corrplot(cor(mtcars_hp_drat))
```

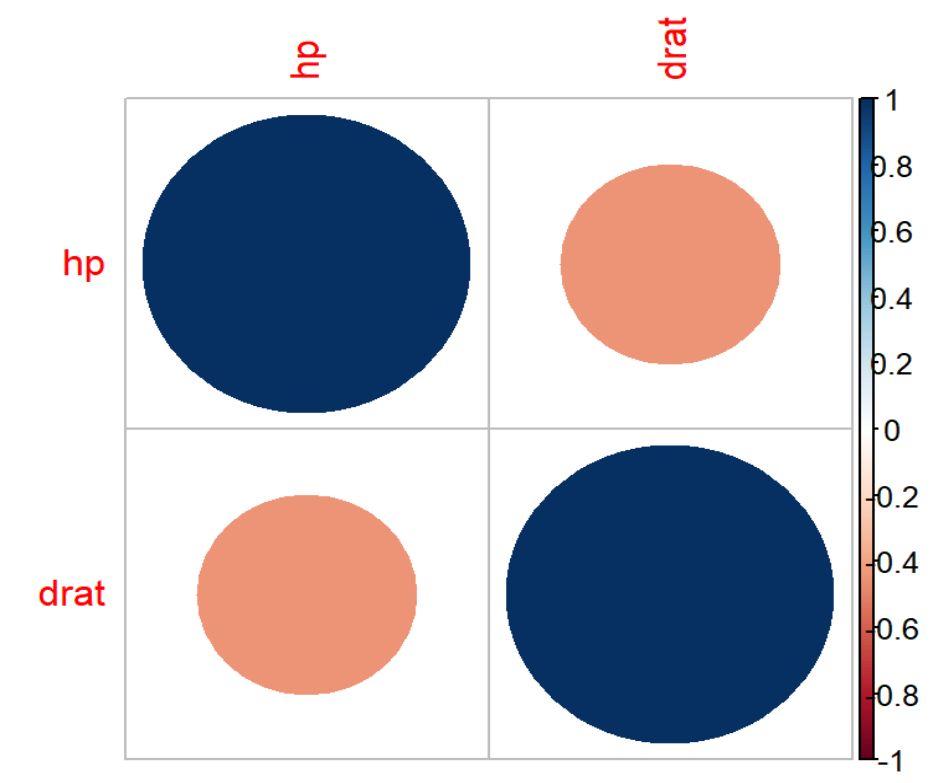

Rysunek 6 Wykres korelacji między zmiennymi hp i drat

Wykres typu corrplot przedstawia najważniejsze czynniki korelacji, czyli:

- ***Kierunek korelacji*** – kolor kół określa w którym kierunku skierowana jest korelacja. Jak widać w komórkach na przecięciach hp i drat kółka są beżowe co wskazuję na ujemną korelacje, czyli ***gdy wartości hp rosną to wartości drat maleją***.
- ***Siła korelacji*** – wielkość kół określa jak silna jest relacja danych. Patrząc na rysunek możemy zauważy, że koła wypełniają znaczną cześć ramki co wskazuje na ***silną korelacje*** między tymi danymi.

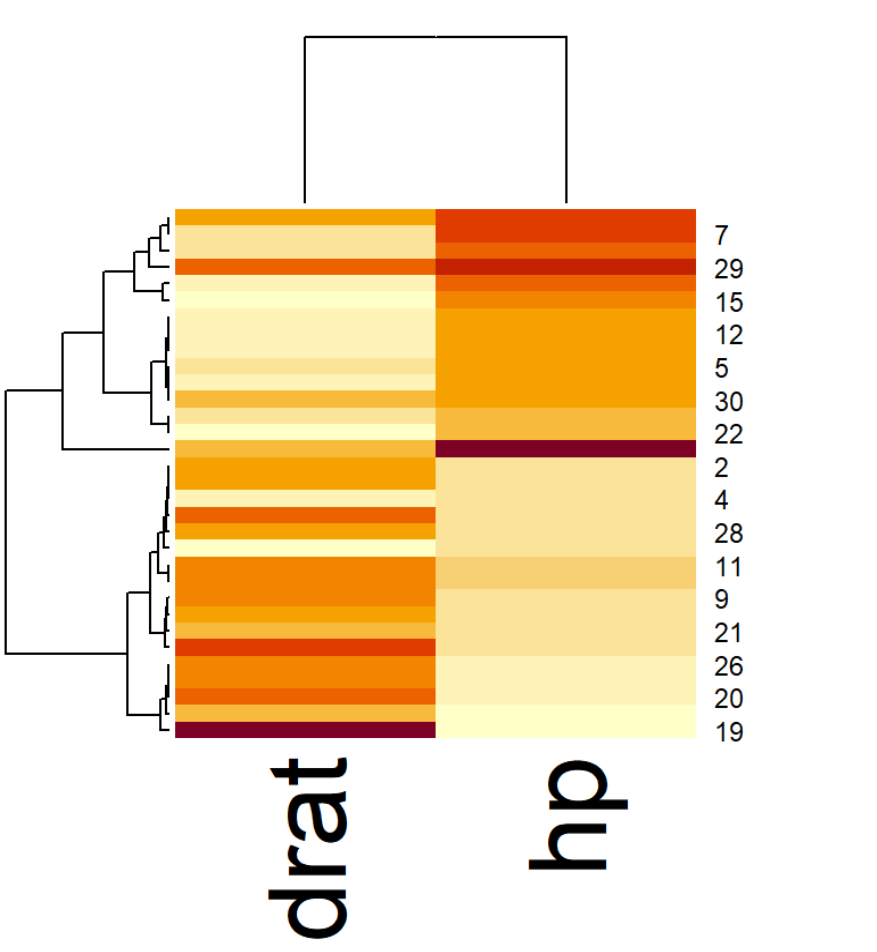

Rysunek 7 Heatmapa wartości zmiennych hp i drat podzielonych na kolumny

Heatmapa:

Jest to wykres pokazujący dla każdej wartości, odpowiedniej zmiennej, kolor, którego jasność obrazuje wielkość tej wartości. Rysunek 7. przedstawia wartości naszych zmiennych hp oraz drat. Bardzo dobrze obrazuje korelację między nimi. Możemy zauważyć, że ***kiedy wartości zmiennej hp rosną*** *(od dołu do góry)* ***wartości zmiennej drat odpowiednio maleją***. Idealnie łączy się to z wcześniejszymi wynikami odnośnie do kierunku ujemnego korelacji.

```
> hp_drat_matrix = as.matrix(mtcars_hp_drat)
> colnames(hp_drat_matrix) = c("hp", "drat")
> heatmap(hp_drat_matrix, scale="column")
```

PODSUMOWANIE

Dane z pakietu „mtcars” pomimo małej próbki danych i kilku wartości odrastających w zmiennej mocy (hp), pozwalają na podstawową analizę i wysnucie wniosków.

Po przeprowadzeniu analizy wszystkie wyniki wskazują na korelację między wielkością mocy a przełożeniem przekładni głównej w samochodach osobowych. Jest ona silna i jednoznaczna a mianowicie ***im większa jest moc auta tym niższe są wartości przełożenia***.

Taki wniosek ma swoje logiczne wytłumaczenie w rzeczywistości. Ta ujemna korelacja może np. być spowodowana chęcią zwiększenia osiągów, ponieważ gdy buduje się samochód z dużą mocą to również stawia się na efektywniejsze przekładnie których przełożenie jest niskie co poprawi przyspieszenie i osiągi na wyższych biegach. Natomiast auta budżetowe budowane z mniejsza mocą wyposażane są w przekładnie w większym przełożeniem co zwiększa wydajność na niższych biegach i ogranicza zużycie paliwa.

WYKORZYSTANY KOD

```
#STATYSTYKI OPISOWE DLA DWOCH CECH - (hp, drat)
data("mtcars")
hist(mtcars$hp)
hist(mtcars$drat)

#import biblioteki e1071 potrzebnej do kurtozy
install.packages('e1071')
library(e1071)

kurtosis(mtcars$hp)
kurtosis(mtcars$drat)

#obrazowanie kurtozy za pomącą wykresu pudełkowego
boxplot(mtcars$hp)
boxplot(mtcars$drat)

#wartosci skrajne hp
min(mtcars$hp)
max(mtcars$hp)

#wartosci skrajne drat
min(mtcars$drat)
max(mtcars$drat)

skewness(mtcars$hp)
skewness(mtcars$drat)


```

```r
#ZMIENNOSC ==============================================================
mean(mtcars$hp)
var(mtcars$hp)
sd(mtcars$hp)

median(mtcars$hp)
max(mtcars$hp) - min(mtcars$hp)
IQR(mtcars$hp)

mean(mtcars$drat)
var(mtcars$drat)
sd(mtcars$drat)

median(mtcars$drat)
max(mtcars$drat) - min(mtcars$drat)
IQR(mtcars$drat)


#ANALIZA KORELACJI ======================================================
#Badamy za pomocą testu Saphiro-Wilka
#czy hp i drat mają rozkład normalny
shapiro.test(mtcars$hp)
shapiro.test(mtcars$drat)

#sprawdzamy korelacje testem spearmana
cor.test(mtcars$hp, mtcars$drat, method = 'spearman', use='complete.obs')


```

```r
#WIZUALIZACJA ==========================================================
install.packages("corrplot")
library(corrplot)
mtcars_hp_drat = data.frame(mtcars$hp, mtcars$drat)
colnames(mtcars_hp_drat) = c("hp", "drat")
corrplot(cor(mtcars_hp_drat))

hp_drat_matrix = as.matrix(mtcars_hp_drat)
colnames(hp_drat_matrix) = c("hp", "drat")
heatmap(hp_drat_matrix, scale="column")
```