Badanie korelacji oczekiwanej długości życia a liczebnością populacji w krajach na świecie

Karol Bartnicki Inżynieria i Analiza Danych AGH

WPROWADZENIE

Oczekiwana długość życia (live expectancy) zależy od bardzo wielu czynników między innymi takich jak warunki życia, poziom ochrony zdrowia oraz rozwój społeczno-ekonomiczny danego regionu. Z kolei poziom zaludnienia może wpływac na dostęp do zasobów, strukturę społeczną i politykę zdrowotną. Intuicyjnie można zakładać, że większa populacja wiąże się zwiększonymi wyzwaniami w zakresie ochrony, zdrowia i jakości życia jednak nie jest to regułą. Wysoko rozwinięte kraje, mimo dużej populacji często charakteryzują się wysoką oczekiwaną długością życia. Natomiast w krajach, rozwijających się, szybki wzrost populacji może prowadzić do problemów związanych z np. niedożywieniem, czyli krótszą długością życia.

Celem tego projektu jest analiza korelacji między oczekiwaną długością życia a liczebnością populacji, bazując na danych z pakietu „gapminder" dla roku 1987. Analiza korelacji między tymi zmiennymi może pomóc w zrozumieniu, czy istnieje zależność między nimi oraz dostarczyłoby to istotnych danych dotyczących czynników wpływających na długość życia.

PODSTAWY TEORETYCZNE

Pakiet „Gapminder” zawiera dane dotyczące różnych wskaźników społeczno-ekonomicznych i demograficznych dla różnych krajów na przestrzeni lat. Jest często wykorzystywany w analizach statystycznych i wizualizacjach danych, ponieważ obejmuje uporządkowane informacje o krajach w ujęciu czasowym. Zawiera dane dla 142 krajów na przestrzeni lat od 1952 do 2007 (co 5 lat).

Oto szczegółowy opis zmiennych z tego pakietu:

1. country – nazwa kraju, dla którego podano dane.
2. continent – kontynent, do którego należy dany kraj.
3. year – rok pomiaru (dostępne są dane co pięć lat od 1952 do 2007).
4. lifeExp – oczekiwana długość życia w danym kraju (średnia liczba lat, jaką może przeżyć noworodek przy zachowaniu bieżących warunków zdrowotnych.
5. pop – liczba ludności w danym kraju w danym roku.
6. gdpPercap – PKB na mieszkańca (produkt krajowy brutto na osobę, wyrażony w dolarach amerykańskich i skorygowany o inflację)

	country	continent	year	lifeExp	pop	gdpPercap
1	Afghanistan	Asia	1952	28.801	8425333	779.4453
2	Afghanistan	Asia	1957	30.332	9240934	820.8530
3	Afghanistan	Asia	1962	31.997	10267083	853.1007
4	Afghanistan	Asia	1967	34.020	11537966	836.1971
5	Afghanistan	Asia	1972	36.088	13079460	739.9811
6	Afghanistan	Asia	1977	38.438	14880372	786.1134
7	Afghanistan	Asia	1982	39.854	12881816	978.0114
8	Afghanistan	Asia	1987	40.822	13867957	852.3959
9	Afghanistan	Asia	1992	41.674	16317921	649.3414
10	Afghanistan	Asia	1997	41.763	22227415	635.3414
11	Afghanistan	Asia	2002	42.129	25268405	726.7341
12	Afghanistan	Asia	2007	43.828	31889923	974.5803
13	Albania	Europe	1952	55.230	1282697	1601.0561
14	Albania	Europe	1957	59.280	1476505	1942.2842
15	Albania	Europe	1962	64.820	1728137	2312.8890

Rysunek 1 Kilka pierwszych wierszy z tabeli danych z pakietu Gapminder

W tym projekcie użyje próbki danych z tego pakietu dla roku 1987.

```
> install.packages("gapminder")
> library(gapminder)
> data('gapminder')
> gapminder_1987 = gapminder[gapminder$year == 1987, ]
> View(gapminder_1987)
```

	country	continent	year	lifeExp	pop	gdpPercap
1	Afghanistan	Asia	1987	40.822	13867957	852.3959
2	Albania	Europe	1987	72.000	3075321	3738.9327
3	Algeria	Africa	1987	65.799	23254956	5681.3585
4	Angola	Africa	1987	39.906	7874230	2430.2083
5	Argentina	Americas	1987	70.774	31620918	9139.6714
6	Australia	Oceania	1987	76.320	16257249	21888.8890
7	Austria	Europe	1987	74.940	7578903	23687.8261
8	Bahrain	Asia	1987	70.750	454612	18524.0241
9	Bangladesh	Asia	1987	52.819	103764241	751.9794

Rysunek 2 Tabela danych z pakietu Gapminder przefiltrowanych dla 1987

Najbardziej skupimy się na zmiennych lifeExp oraz pop.

```
> hist(gapminder_1987$pop)
> hist(gapminder_1987$lifeExp)
```

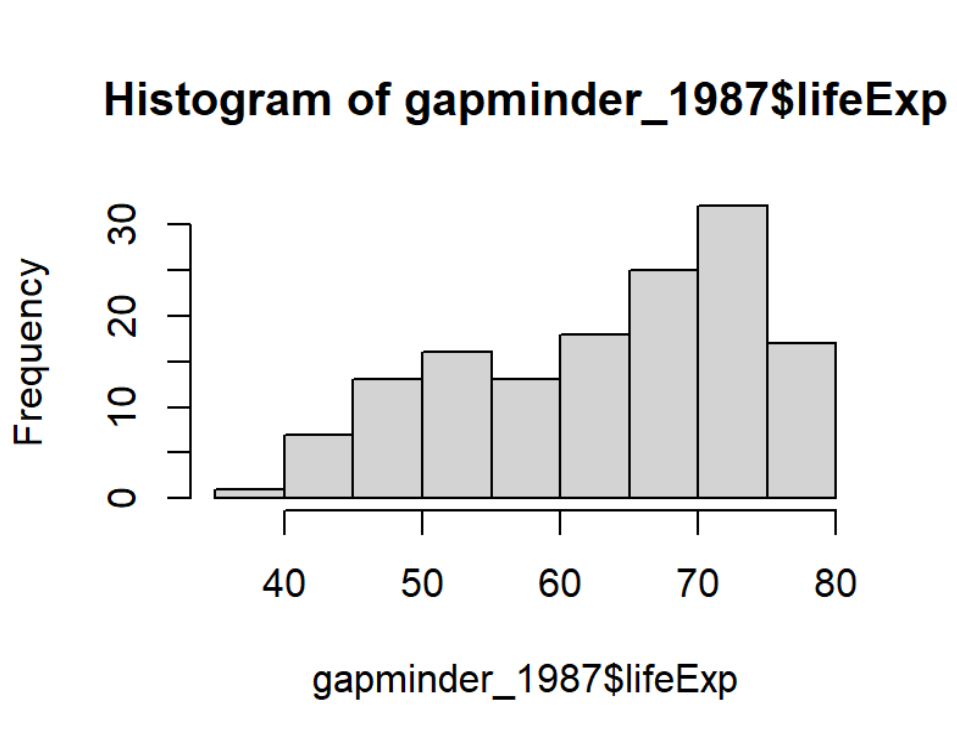

Rysunek 4 Histogram zmiennej lifeExp dla 1987

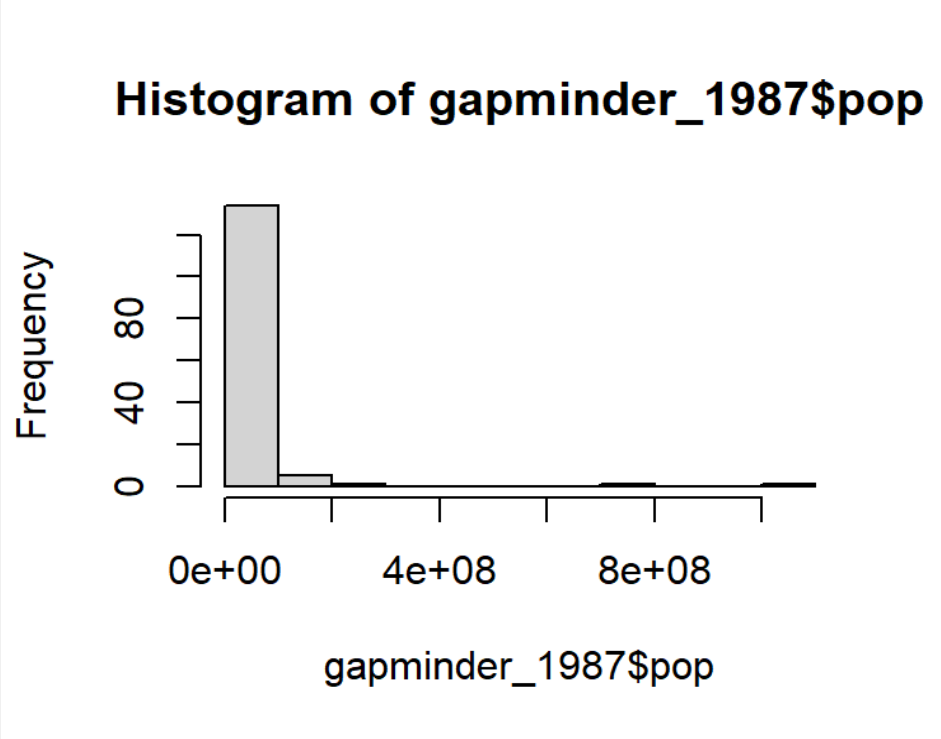

Rysunek 3 Histogram zmiennej pop dla 1987

Do obliczenia i przedstawienia danych statystycznych tej próbki danych użyję podstawowych funkcji z języka programowania R:

- mean() – oblicza średnią arytmetyczną podanej listy danych.
- median() – oblicza medianę, czyli wartość środkową uporządkowanego zbioru danych.
- min() – zwraca najmniejszą wartość w podanym zbiorze danych.
- max() – zwraca największą wartość w podanym zbiorze danych.
- sd() - oblicza odchylenie standardowe, czyli miarę rozproszenia danych względem śr.
- var() - oblicza wariancję, czyli miarę zmienności danych.
- IQR() - zwraca rozstęp, czyli różnicę między trzecim a pierwszym kwartylem (Q3 - Q1).
- shapiro.test() - przeprowadza test Shapiro-Wilka na normalność rozkładu danych.
- cor.test() - przeprowadza test korelacji między dwiema zmiennymi.
- hist() - rysuje histogram rozkładu danych.
- boxplot() - tworzy wykres pudełkowy.
- skewness() - oblicza skośność rozkładu, asymetrię rozkładu wartości względem średniej.
- heatmap() – tworzy heatmapę gdzie kolorem ilustruje wielkość wartości zmiennej.
- pairs() – tworzy wykres relacji między wartościami zmiennych z różnych perspektyw.
- kurtosis() - oblicza kurtozę, czyli miarę spłaszczenia rozkładu. Z biblioteki „e1071”.
- corrplot() – tworzy wykres obrazujący siłę i kierunek korelacji. Z biblioteki „corrplot”.

CZĘŚĆ ANALITYCZNA I WYNIKI

Opis i wskazanie relacji pomiędzy populacją a oczekiwaną długością życia:

```
> pairs(~pop+lifeExp, data=gapminder_1987)
```

Aby sprawdzić wzajemne oddziaływanie na siebie tych zmiennych stworzyłem wykres relacji pomiędzy wartościami pop oraz lifeExp. Jak widzimy zmienna ***pop ma kilka wartości od krajów o bardzo dużej populacji*** (powyżej 1 miliarda). Mimo tak skrajnych wartości, ***wartość lifeExp dla tych krajów nie różni się znacznie od pozostałych***, a nawet utrzymuje się w pobliżu mediany. Niestety przez tak duże wartości wykres jest praktycznie nieczytelny, dlatego aby przyjrzeć się reszcie punktów musimy zmienić skalę na logarytmiczną.

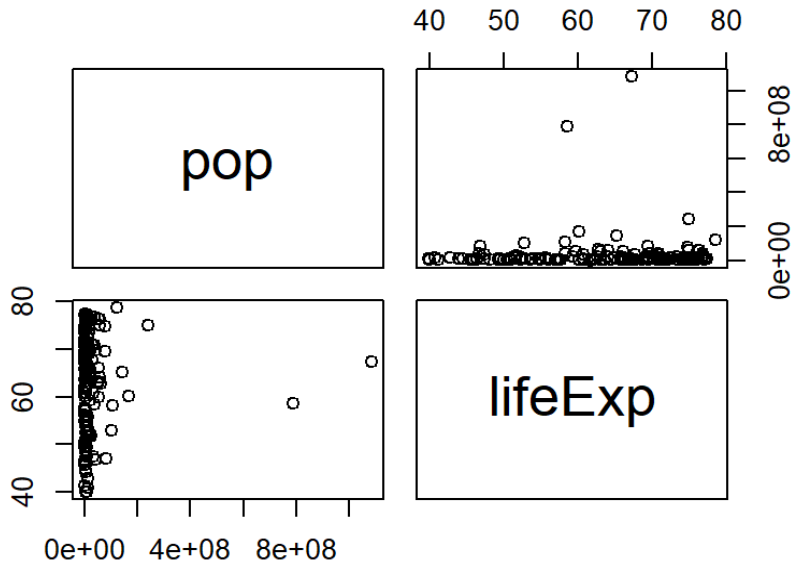

Rysunek 5 Wykres wartości zmiennych pop i lifeExp z dwóch perspektyw

```
> plot(gapminder_1987$pop, gapminder_1987$lifeExp, log="x", xlab="population", ylab="life_expectancy")
```

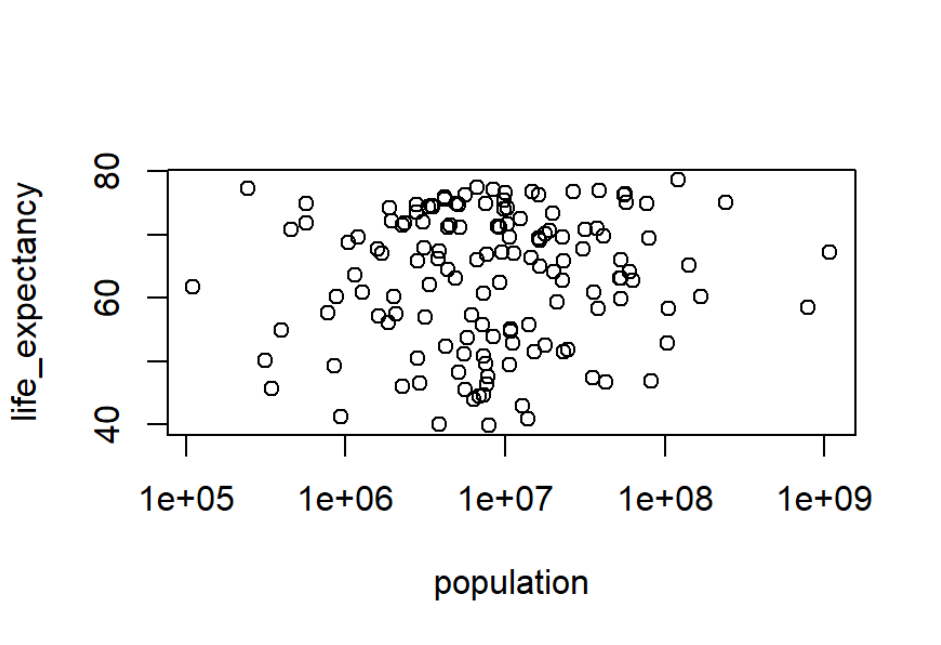

Rysunek 6 Wykres wartości zmiennych pop i lifeExp w skali logarytmicznej

Analiza wykresu:

Po stworzeniu wykresu ze skalą logarytmiczną możemy lepiej przyjrzeć się pozostałym wartościom. Niestety ***punkty są rozproszone bez żadnego widocznego wzorca*** co sugeruje brak silnej relacji między zmiennymi. Ponadto nie obserwujemy rosnącego ani malejącego trendu, co oznacza, że ***populacja kraju nie wpływa bezpośrednio na oczekiwaną długość życia***.

Sprawdzenie rozkładów danych, a następnie wyliczenie korelacji.

Aby wybrać odpowiednie narzędzie do badania korelacji między zmiennymi musimy mieć pewność jaki mają one rozkład danych. Z dotychczasowej analizy wynika, że rozkład zmiennej hp znacznie różni się od rozkładu normalnego. Aby się upewnić użyjemy testu ***Shapiro-Wilka***, który jest standardowym narzędziem wykorzystywanym do sprawdzenia normalności danych, ponieważ wyróżnia go duża moc.

```
> shapiro.test(gapminder_1987$pop)

        Shapiro-Wilk normality test

data:  gapminder_1987$pop
W = 0.24574, p-value < 2.2e-16
```

Zmienna pop:

Wynik testu (wartość W) jest bardzo mały (<0.50) co jest już wystarczającym dowodem, że ***dane zmiennej bardzo odbiegają od rozkładu normalnego.***

Zmienna lifeExp:

Wynik jest całkiem duży (>0.90), natomiast wartość parametru p jest dużo mniejsza od ustalonej wartości (0.05), więc te ***dane również nie charakteryzują się rozkładem normalnym.***

```
> shapiro.test(gapminder_1987$lifeExp)

        Shapiro-Wilk normality test

data:  gapminder_1987$lifeExp
W = 0.93502, p-value = 3.966e-06
```

W tym przypadku dane bardzo odbiegają od rozkładu normalnego, więc należy użyć odpowiedniego testu korelacji. Służy do tego test korelacji rang ***Spearmana***, stosowany w przypadku naruszenia założenia normalności. Wywołujemy go funkcją cor.test() z dodatkowym parametrem (method = 'spearman').

W wyniku istotna jest wartość p (p-value) oraz ostateczny wynik na samym dole. Parametr p to wysokość prawdopodobieństwa, że korelacja między danymi wystąpiła przypadkowo – ***hipoteza zerowa***.

```
> cor.test(gapminder_1987$pop, gapminder_1987$lifeExp, method = 'spearman', use='complete.obs')

        Spearman's rank correlation rho

data:  gapminder_1987$pop and gapminder_1987$lifeExp
S = 451700, p-value = 0.5278
alternative hypothesis: true rho is not equal to 0
sample estimates:
       rho
0.05341892
```

Interpretacja wyników:

Wartość prawdopodobieństwa p jest bardzo duża i oznacza ona, że szanse na prawdziwość hipotezy zerowej jest większa niż 50% (52.8%). Jest więc bardzo możliwe, że korelacja, jeżeli wystąpiła to tylko przypadkowo.

Wynik główny natomiast jest bardzo niski (w tym kryterium nie zwracamy uwagi na znak) co oznacza, że ***związek między danymi jest znikomy***. Fakt, że jest to liczba dodatnia wskazywałby, że wzrost jednej zmiennej, czyli populacji wpływałby na wzrost drugiej, czyli oczekiwanej długości życia, jednak patrząc na poprzednie wyniki widać, że jest to słaba oraz bardzo przypadkowa zależność.

WYNIKI

Zobrazowanie wyników przeprowadzonej analizy oraz wzajemnej korelacji zmiennej pop jako populacji oraz lifeExp jako oczekiwanej dł. życia.

```
> install.packages("corrplot")
> library(corrplot)
> gapminder_pop_lifeExp = data.frame(log10(gapminder_1987$pop), gapminder_1987$lifeExp)
> colnames(gapminder_pop_lifeExp) = c("pop", "lifeExp")
> corrplot(cor(gapminder_pop_lifeExp), method = "circle")
```

log10(gapminder_1987$pop) w tworzeniu ramki danych zapewnia nam skalę logarytmiczną przy tworzeniu wykresów.

Wykres typu corrplot przedstawia najważniejsze czynniki korelacji:

Siła korelacji - jak możemy zauważyć w polach na przecięciu pop i lifeExp kółka są bardzo małe co pokazuje, że korelacja praktycznie nie istnieje między tymi zmiennymi.

Kierunek korelacji - wskazywany przez kolor, który jest na tyle bliski zeru (kolor biały), że nie jest odczytywalny. Jednak przy braku korelacji nie ma to żadnego znaczenia.

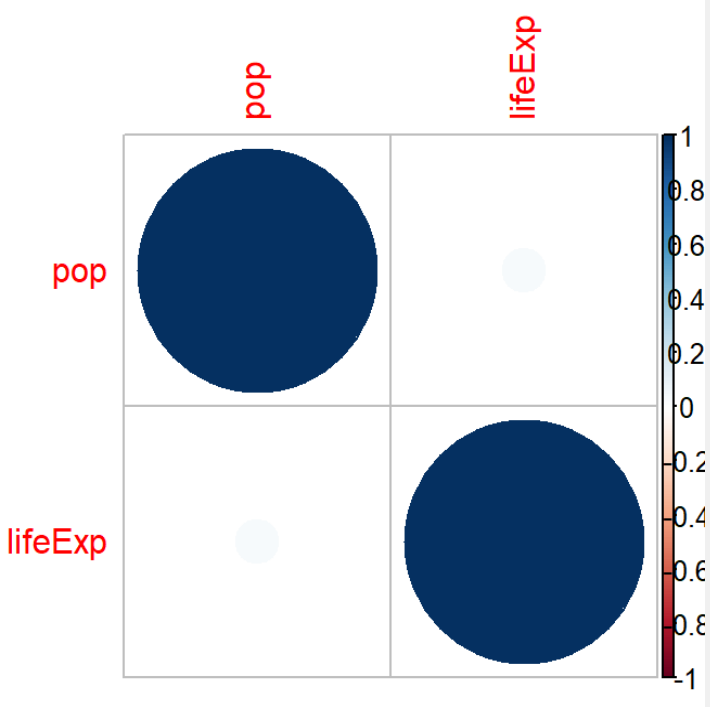

Rysunek 7 Wykres korelacji między populacją a oczekiwaną długością życia.

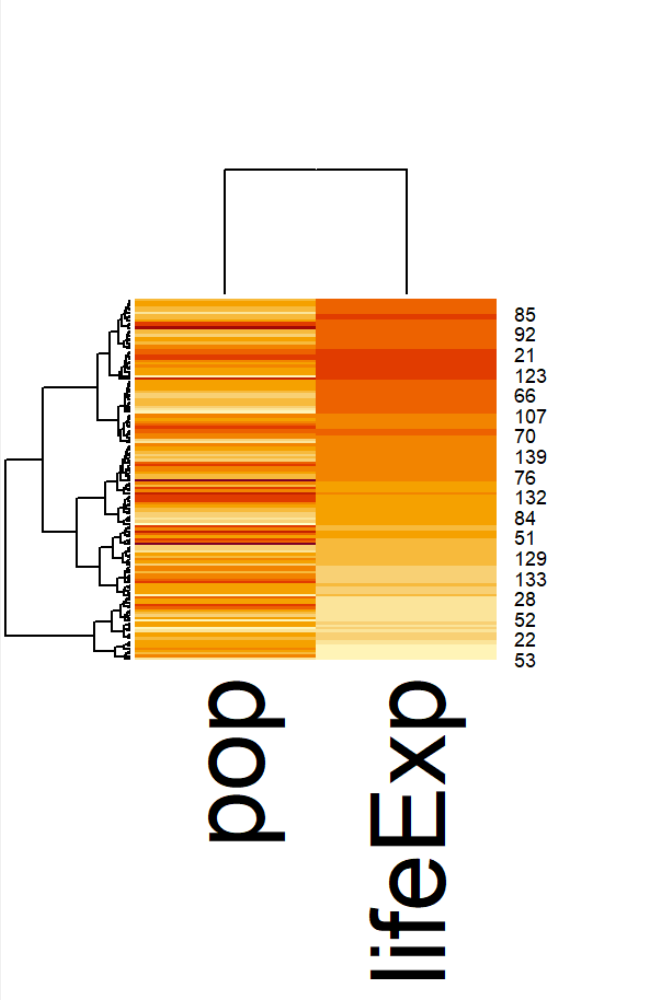

Rysunek 8 Heatmapa wartości zmiennych pop i lifeExp podzielonych na kolumny.

```
> heatmap(as.matrix(gapminder_pop_lifeExp), scale="column")
```

Heatmapa:

Jest to wykres pokazujący dla każdej wartości, odpowiedniej zmiennej, kolor, którego jasność obrazuje wielkość tej wartości. Rysunek 8. przedstawia wartości naszych zmiennych pop oraz lifeExp. Nie jest tu widoczna żadna zależność między danymi. Podczas ***kiedy wartości zmiennej lifeExp rosną*** *(od dołu do góry)* ***wartości zmiennej pop przyjmują bardzo rozstrzelone wartości***. Idealnie łączy się to z wcześniejszymi wynikami odnośnie do braku korelacji między danymi.

PODSUMOWANIE

Dane z pakietu „gapminder” są bardzo obszernym i kompletnym zbiorem i pozwalają na podstawową analizę i wysnucie wniosków.

Zarówno w wyniku zwykłej analizy wykresu jak i przeprowadzenia testu korelacji wynika, że wartości zmiennych pop i lifeExp nie korelują ze sobą, oznacza to, że ***liczebność populacji nie oddziałuje na oczekiwaną długość życia w danym kraju***. W praktyce populacja bardziej zależy od obszaru, który kraj zajmuje natomiast na oczekiwaną długość życia najbardziej wpływa efektywność kraju w zarządzaniu swoimi zasobami.

WYKORZYSTANY KOD

```
#STATYSTYKI OPISOWE DLA DANYCH Z PAKIETU ''danych z pakietu gapminder dla roku 1987

install.packages("gapminder")
library(gapminder)
data('gapminder')

#filtrujemy do roku 1987
gapminder_1987 = gapminder[gapminder$year == 1987, ]

hist(gapminder_1987$pop)
hist(gapminder_1987$lifeExp)
pairs(~pop+lifeExp, data=gapminder_1987)
plot(gapminder_1987$pop, gapminder_1987$lifeExp, log="x", xlab="population", ylab="life_expectancy")

#Badamy za pomocą testu Shapiro-Wilka czy hp jest układem normalnym
shapiro.test(gapminder_1987$pop)
shapiro.test(gapminder_1987$lifeExp)

#sprawdzamy korelacje testem Spearmana
cor.test(gapminder_1987$pop, gapminder_1987$lifeExp, method = 'spearman', use='complete.obs')

#wizualizacja
install.packages("corrplot")
library(corrplot)
gapminder_pop_lifeExp = data.frame(log10(gapminder_1987$pop), gapminder_1987$lifeExp)
colnames(gapminder_pop_lifeExp) = c("pop", "lifeExp")
corrplot(cor(gapminder_pop_lifeExp), method = "circle")
heatmap(as.matrix(gapminder_pop_lifeExp), scale="column")
```