Preprocessing i analiza danych z Titanica

Karol Bartnicki Inżynieria i Analiza Danych AGH

WPROWADZENIE

Tą pracę oprę o plik *titanic_new.csv,* który zawiera dane o Titanicu, czyli niezwykle sławnym statku, który w 1912 podczas swojego dziewiczego rejsu na trasie Southampton-Cherbourg-Queenstown-Nowy Jork, RMS nieszczęśliwie zderzył się z górą lodową i zatonął. W tym sprawozdaniu przedstawię relację między zmiennymi a śmiertelnością tej katastrofy.

Aby osiągnąć mój cel posłużę się najpierw preprocessingiem do uproszczenia i odpowiedniego przygotowania danych. Preprocessing jest kluczowym działaniem w dziedzinie data science, jego zadaniem jest wstępna obróbka i przetwarzanie informacji. Zakłada ona czyszczenie, przekształcanie oraz integrowanie zebranych wiadomości tak, by dzięki metodom analityczno-statystycznym można było stworzyć na ich podstawie modele danych jak najwierniejsze rzeczywistości oraz na podstawie analiz wyciągać prawidłowe wnioski.

Plik titnic_new.csv użyty w projekcie zawiera następujące kolumny:

- Passenger.Id – numer porządkowy pasażera w pliku.
- Survived – 1 jeśli pasażer przeżył katastrofę, 0 jeśli nie.
- Pclass – numer klasy pasażera (1, 2 lub 3).
- Name – imię i nazwisko pasażera wraz z tytułem (Mr., Mrs., Miss.)
- Sex – płeć (male lub female).
- Age – wiek.
- SibSp – (Siblings/Spouses) zawiera listę rodzeństwa lub małżonków pasażera (typ integer określa liczbę bliskich, z którymi podróżowała dana osoba). q
- Pearch – (Parents/Children) informuje o liczbie rodziców lub dzieci, które podróżowały z pasażerem
- Ticket – numer biletu pasażera.
- Fare – opłata biletowa (cena podróży).
- Cabin – oznaczenie kabiny, w której zameldowany był pasażer (silnie wybrakowana kolumna danych).
- Embarked – oznaczenie portu, w którym dany pasażer wszedł na pokład statku. S – Southampton, C – Cherbourg, Q – Queenstown.

	Passenger.Id	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	1	0	3	Braund, Mr. Owen Harris	male	22.00	1	0	A/5 21171	'7.25'		S
2	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38.00	1	0	PC 17599	'71.2833'	C85	C
3	3	1	3	Heikkinen, Miss. Laina	female	26.00	0	0	STON/O2. 3101282	'7.925'		S
4	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.00	1	0	113803	'53.1'	C123	S
5	5	0	3	Allen, Mr. William Henry	male	35.00	0	0	373450	'8.05'		S
6	6	0	3	Moran, Mr. James	male	NA	0	0	330877	'8.4583'		Q
7	7	0	1	McCarthy, Mr. Timothy J	male	54.00	0	0	17463	'51.8625'	E46	s
8	8	0	3	Palsson, Master. Gosta Leonard	male	2.00	3	1	349909	'21.075'		s
9	9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.00	0	2	347742	'11.1333'		S
10	10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.00	1	0	237736	'30.0708'		C
11	11	1	3	Sandstrom, Miss. Marguerite Rut	female	4.00	1	1	PP 9549	'16.7'	G6	s
12	12	1	1	Bonnell, Miss. Elizabeth	female	58.00	0	0	113783	'26.55'	C103	S
13	13	0	3	Saundercock, Mr. William Henry	male	20.00	0	0	A/5. 2151	'8.05'		s
14	14	0	3	Andersson, Mr. Anders Johan	male	39.00	1	5	347082	'31.275'		S
15	15	0	3	Vestrom, Miss. Hulda Amanda Adolfina	female	14.00	0	0	350406	'7.8542'		S

```
titanic = read.csv('titanic_new.csv', header=TRUE, sep=',')
view(titanic)
```

PODSTAWY TEORETYCZNE

Do przygotowania danych do analizy wykorzystano następujące funkcje z języka R:

- is.na() – sprawdzenie brakujących danych (NA),
- distinct()-usunięci duplikatów (dyplr)
- unique() – identyfikacja unikalnych wartości w kolumnach,
- table() – tworzenie tabeli zliczającej wystąpienia wartości,
- as.numeric() – konwersja danych na format numeryczny,
- typeof() – sprawdzenie typu danych,
- str_replace_all() – zamiana znaków w ciągach tekstowych,
- select()-wybiera kolumny z ramki danych
- impute()-uzupełnia dane
- %in% – sprawdzenie przynależności wartości do zbioru,
- names(sort(table(<tablica>), decreasing = TRUE))[1] – wyliczenie najczęściej powatarzającej się wartości w kolumnie (moda).

Do obliczenia i przedstawienia danych statystycznych tej próbki danych użyję podstawowych funkcji z języka programowania R:

- mean() – oblicza średnią arytmetyczną podanej listy danych.
- median() – oblicza medianę, czyli wartość środkową uporządkowanego zbioru danych.
- min() – zwraca najmniejszą wartość w podanym zbiorze danych.
- max() – zwraca największą wartość w podanym zbiorze danych.
- sd() - oblicza odchylenie standardowe, czyli miarę rozproszenia danych względem śr.
- var() - oblicza wariancję, czyli miarę zmienności danych.
- IQR() - zwraca rozstęp, czyli różnicę między trzecim a pierwszym kwartylem (Q3 - Q1).
- shapiro.test() - przeprowadza test Shapiro-Wilka na normalność rozkładu danych.
- cor.test() - przeprowadza test korelacji między dwiema zmiennymi.
- hist() - rysuje histogram rozkładu danych.
- boxplot() - tworzy wykres pudełkowy.
- skewness() - oblicza skośność rozkładu, asymetrię rozkładu wartości względem średniej.
- heatmap() – tworzy heatmapę gdzie kolorem ilustruje wielkość wartości zmiennej.
- kurtosis() - oblicza kurtozę, czyli miarę spłaszczenia rozkładu. Z biblioteki „e1071”.
- corrplot() – tworzy wykres obrazujący siłę i kierunek korelacji. Z biblioteki „corrplot”.

DATA CLEANING

1. **Dane nieistotne** - Sprawdzamy które dane nie będą istotne w naszej analizie

Zauważamy, że niektóre kolumny nie są niezbędne w późniejszej analizie. Kolumna ***Passenger.Id*** możemy zastąpić numerem wiersza więc nie jest nam potrzebne. Dodatkowo kolumny ***Name*** i ***Ticket*** zawierają unikalne nazwy których nie będziemy w stanie połączyć ze sobą więc nie są potrzebne w naszej analizie.

```
> titanic = titanic %>% select(-Passenger.Id, -Ticket, -Name)
> view(titanic)
```

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Cabin	Embarked
1	0	3	male	22.00	1	0	'7.25'		S
2	1	1	female	38.00	1	0	'71.2833'	C85	C
3	1	3	female	26.00	0	0	'7.925'		S
4	1	1	female	35.00	1	0	'53.1'	C123	S
5	0	3	male	35.00	0	0	'8.05'		S
6	0	3	male	NA	0	0	'8.4583'		Q
7	0	1	male	54.00	0	0	'51.8625'	E46	s
8	0	3	male	2.00	3	1	'21.075'		s
9	1	3	female	27.00	0	2	'11.1333'		S
10	1	2	female	14.00	1	0	'30.0708'		C
11	1	3	female	4.00	1	1	'16.7'	G6	s
12	1	1	female	58.00	0	0	'26.55'	C103	S
13	0	3	male	20.00	0	0	'8.05'		s
14	0	3	male	39.00	1	5	'31.275'		S
15	0	3	female	14.00	0	0	'7.8542'		S

2. **Duplikaty** – Szukamy powtarzających się wierszy, które mogą utrudnić nam przyszłą analizę

Aby sprawdzić czy jest to konieczne, liczymy unikalne wartości i porównujemy je z łączną liczbą wierszy. W naszym przypadku ponad sto wierszy nie jest unikalnych, więc stosujemy funkcję usunięcia duplikatów.

```
> nrow(titanic)
[1] 891
> nrow(unique(titanic))
[1] 785
> titanic = distinct(titanic)
```

3. **Niepoprawny typ danych** – Dostosowujemy typy danych w poszczególnych kolumnach, aby móc łatwiej się do nich odnosić i je edytować.

```
> sapply( titanic, typeof )
   Survived      Pclass         Sex         Age       SibSp       Parch        Fare       Cabin    Embarked
  "integer"   "integer" "character"    "double"   "integer"   "integer" "character" "character" "character"
```

Zamieniamy kolumnę ***Fare*** na double oraz tam gdzie „” w ***Embarked*** na *NA* typu numeric.

```
> titanic$Fare = str_replace_all(titanic$Fare, "'", "")
> titanic$Fare = as.numeric(titanic$Fare)
```

```
> titanic$Embarked[titanic$Embarked == ""] = as.numeric(titanic$Embarked)
```

4. **Szum** – Sprawdzamy czy wszystkie wartości są poprawnie napsane oraz mają sensowne wartości. Sprawdzamy dla kolumn kolejno ***Survived, Pclass, Sex, Embarked*** wszystkie unikalne wartości aby wykryć ewentualne anomalie.

```
> unique(titanic$Survived)
[1]   0   1 111  -1 112
```

```
> unique(titanic$Pclass)
[1] 3 1 2
> unique(titanic$Sex)
[1] "male"    "female"  "feemale" "mal3e"   "mal4e"   "malle"   "malwe"   "f2emale"
> unique(titanic$Embarked)
[1] "S" "C" "Q" "s" ""
```

Jak widzimy w tabeli ***Survived*** pojawiają się wartości różne od 0 i 1 co nie powinno mieć miejsca. Jest to prawdopodobnie błąd w próbie wpisania 1 i należy zamienić te wartości na 1. Podobna sytuacja pojawia się w ***Sex*** i ***Embarked,*** gdzie liczne literówki oraz pisanie z małej litery zamiast wielką, znacząco utrudniłaby nam analizę , dlatego wszystko ujednolicamy.

```
> titanic$Survived[titanic$Survived %in% c(-1, 111, 112)] = 1
> titanic$Sex[titanic$Sex %in% c("mal3e", "mal4e", "malle", "malwe")] = "male"
> titanic$Sex[titanic$Sex %in% c("feemale", "f2emale")] = "female"
> titanic$Embarked[titanic$Embarked %in% "s"] = "S"
```

Kolumna ***Pclass*** nie ma żadnych niespodziewanych wartości, więc zostawiamy bez zmian.

Dodatkowo sprawdzamy sensowność pozostałych kolumn liczbowych, czyli ***Age, SibSp, Parch***, tak aby nie były one mniejsze od 0 oraz wiek nie był niemożliwie duży. Jednak wszystkie wartości spełniały kryteria i żadna nie zmieniła się na NA.

```
titanic$Age[titanic$Age < 0] = NA
titanic$Age[titanic$Age > 120] = NA
titanic$SibSp[titanic$SibSp < 0] = NA
titanic$Parch[titanic$Parch < 0] = NA
```

Należy również usunąć kolumnę ***Cabin*** mimo jej przydatności, ponieważ jej za bardzo wybrakowana.

```
> titanic = titanic %>% select(-Cabin)
```

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
1	0	3	male	22.00	1	0	7.2500	S
2	1	1	female	38.00	1	0	71.2833	C
3	1	3	female	26.00	0	0	7.9250	S
4	1	1	female	35.00	1	0	53.1000	S
5	0	3	male	35.00	0	0	8.0500	S
6	0	3	male	NA	0	0	8.4583	Q

5. Brakujące Dane – Na sam koniec aby ułatwić późniejszą analizę musimy uzupełnić braki danych.

Wykonamy imputację w kolumnie ***Age*** oraz ***Embarked***. Wiek uzupełnimy medianą aby nie zaburzać wyników, natomiast dla portów ze względu na typ jego danych użyjemy mody.

```
> titanic$Age = impute(titanic$Age, median)
> moda_embarked = names(sort(table(titanic$Embarked), decreasing = TRUE))[1]
> titanic$Embarked[is.na(titanic$Embarked)] = moda_embarked
> view(titanic)
```

SKUTKI PREPROCESSINGU

Po tak dokładnym preprocessingu możemy przejść do szukania relacji między zmiennymi jak i wyliczania innych statystyk bez obawy o błędy spowodowane szumami, brakami w danych czy złymi typami. Dodatkowo cała analiza będzie płynniejsza dzięki pozbyciu się niepotrzebnych kolumn z danymi, które tylko komplikowałyby wszelką obróbkę.

CZĘŚĆ ANALITYCZNA

Badanie relacji między zmiennymi a śmiertelnością

Dane z kolumny ***Survived*** określone są za pomocą dwóch liczb: 0-zmarły i 1-żyjący, dlatego też możemy łatwo odczytać ilość ofiar rejsu.

```
> table(titanic$Survived)

  0   1
462 323
```

Możemy też przedstawić to w wyniku procentowym aby łatwiej zobrazować statystykę.

```
> titanic_cpy = titanic %>% select(Survived)
> titanic_cpy = titanic_cpy[titanic_cpy$Survived == 0, ]
> deth_procentile = length(titanic_cpy)/nrow(titanic)
> deth_procentile * 100
[1] 58.8535
```

Nasza analiza koncentruje się na identyfikacji czynników, które mogły mieć istotny wpływ na szanse pasażerów na ocalenie. Można przypuszczać, że kluczową rolę odegrały takie zmienne jak płeć, wiek oraz status społeczno-ekonomiczny, częściowo odzwierciedlony przez klasę zakupionego biletu.

Przechodząc do charakterystyki danych pod względem płci, dochodzimy do wniosku, że ***o wiele większą szansę na przeżycie miały kobiety*** (aż trzykrotna przewaga procentowa mężczyzn pod względem śmiertelności). Może być to spowodowane pierwszeństwem w kolejności ewakuacji dla

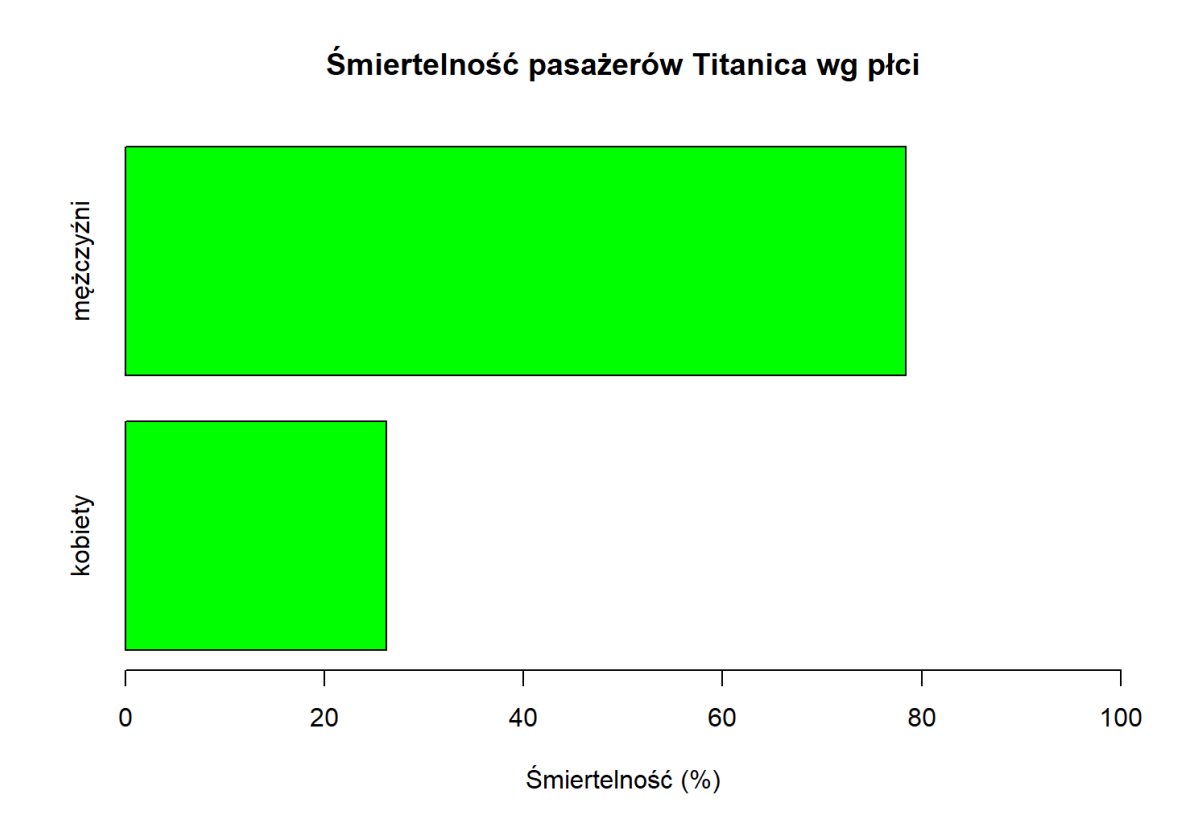

kobiet i dzieci. Warto też dodać że mężczyzn na pokładzie było prawie dwukrotnie więcej niż kobiet.

```
> table(titanic$Sex)

female   male
   294    491
```

Te wnioski podsuwają nam kolejną możliwą zależność, czyli wiek pasażerów.

```
> titanic_cpy = titanic %>% select(Survived, Sex)
> titanic_cpy = titanic_cpy[titanic_cpy$Survived == 0, ]
> death_sex = table(titanic_cpy$Sex)/table(titanic$Sex)
> death_sex * 100

  female     male
26.19048 78.41141
```

Dzięki zbadaniu śmiertelności pasażerów Titanica według grup wiekowych możemy ponownie zauważyć poprzedni wniosek odnośnie pierwszeństwa ewakuacji dla kobiet i dzieci. ***Osoby w wieku poniżej 18 roku poniosły śmierć w najmniejszej ilości***. Dodatkowo widzimy ***największy procent śmiertelności u osób 50+.***

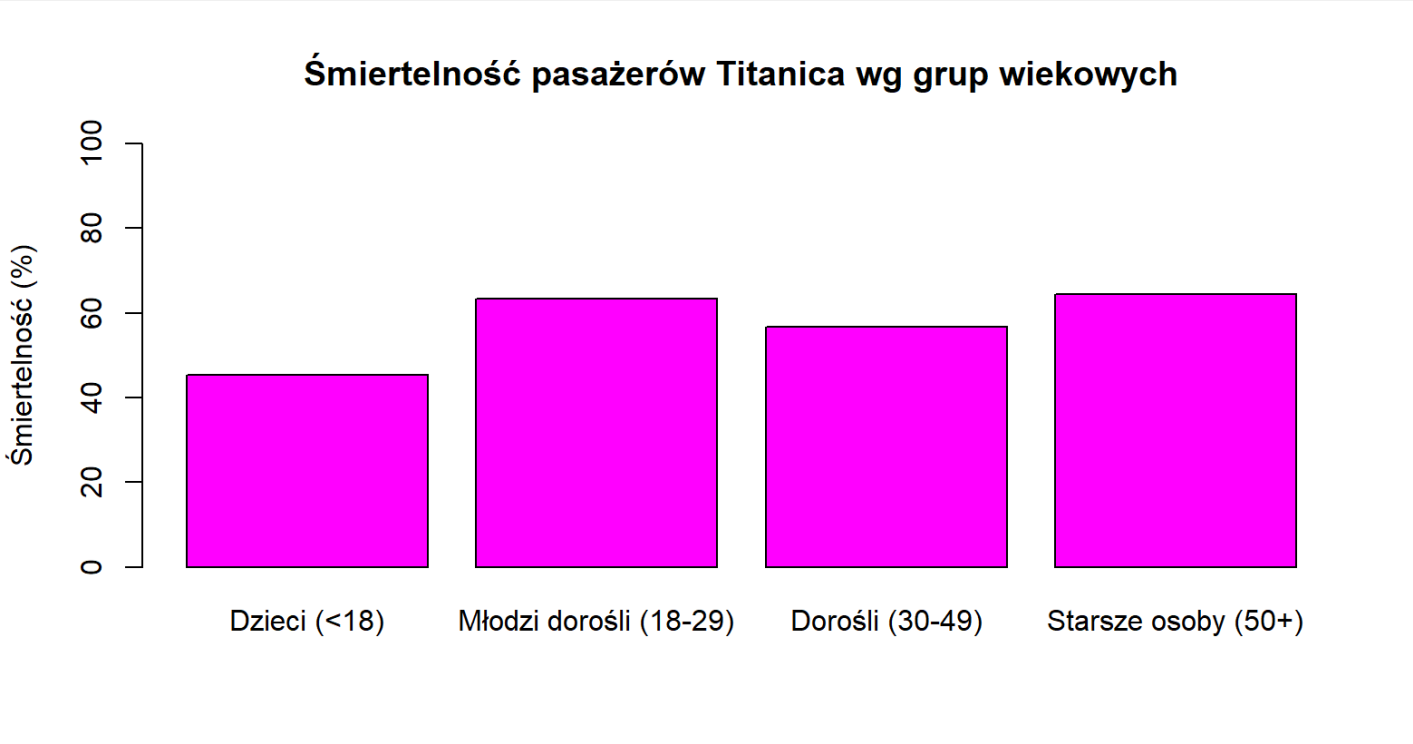


```
> death_children = nrow(titanic[titanic$Age < 18 & titanic$Survived == 0,  ]) / nrow(titanic[titanic$Age < 18,  ])
> death_children * 100
[1] 45.45455
> death_young_adult = nrow(titanic[titanic$Age >= 18 & titanic$Age < 30 & titanic$Survived == 0,  ]) / nrow(titanic[titanic$Age >= 18 & titanic$Age < 30,  ])
> death_young_adult * 100
[1] 63.30532
> death_adult = nrow(titanic[titanic$Age >= 30 & titanic$Age < 50 & titanic$Survived == 0,  ]) / nrow(titanic[titanic$Age >= 30 & titanic$Age < 50,  ])
> death_adult * 100
[1] 56.73469
> death_olders = nrow(titanic[titanic$Age >= 50 & titanic$Age < 120 & titanic$Survived == 0,  ]) / nrow(titanic[titanic$Age >= 50 & titanic$Age < 120,  ])
> death_olders * 100
[1] 64.38356
```

Ostatnim rozważanym czynnikiem jest status materialny poszczególnych pasażerów. Na potrzeby analizy przyjmujemy, że reprezentacją tego aspektu jest klasa kupionego biletu. Z poniższych wyników możemy ustalić, że ***im niższa klasa, tym mniejsze szanse na przeżycie***.

Było to spowodowane prawdopodobnie rangą osób z wyższych klas co skutkowało w pierwszeństwie ewakuacji. Natomiast najniższą klasę w znaczniej większości zostawiono samej sobie co dokładnie widzimy na wykresie obok.

```
> table(titanic$Pclass)

  1   2   3
214 165 406
```

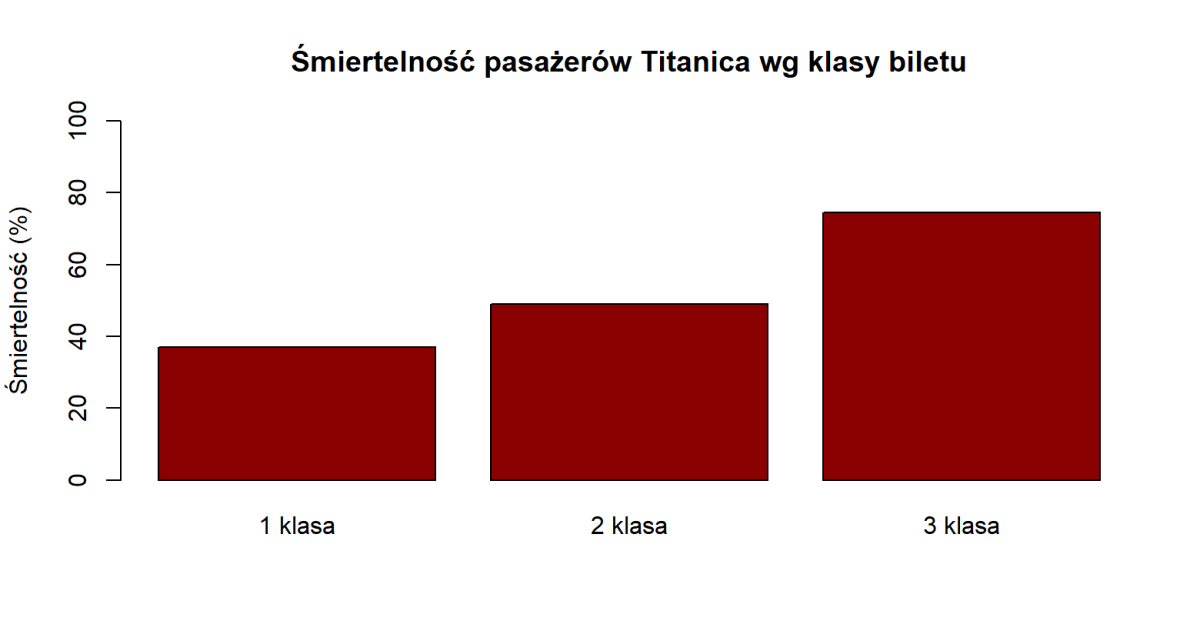

Niestety możemy też zauważyć, że w ***owej 3 klasie znajdowało się więcej osób niż w 1 i 2 razem wziętej***.

```
> titanic_cpy = titanic_cpy[titanic_cpy$Survived == 0, ]
> death_class = table(titanic_cpy$Pclass)/table(titanic$Pclass)
> death_class * 100

        1        2        3
36.91589 49.09091 74.38424
```

Obliczenie podstawowych statystyk dla kolumny z wiekiem pasażerów

```
> summary(titanic$Age)

 107 values imputed to 28.25

   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   0.42   22.00   28.25   29.65   36.00   80.00
```

Używamy funkcji *summary()* do przedstawienia najbardziej podstawowych statystyk kolumny ***Age.***

Następnie obliczamy bardziej zaawansowane statystyki. Otrzymane odchylenie standardowe przyrównujemy do średniej arytmetycznej tego zbioru. Wynosi ono 30-50% średniej co jest dużym wynikiem, więc ***wartości są daleko od średniej***. Rozstęp kwartylowy nie stanowi nawet 30% rozstępu, czyli jest niski. Oznacza to, że ***wartości są skupione wokół mediany***. Natomiast rozstęp jest dużo wyższy od średniej, co wskazuje na ***wartości odrastające***, które widać na wykresie pudełkowym.

```
> var(titanic$Age)
[1] 188.4101
> IQR(titanic$Age)
[1] 14
> sd(titanic$Age)
[1] 13.72625
> max(titanic$Age) - min(titanic$Age)
[1] 79.58
```

Skośność jest raczej niska, więc wykres może przypominać rozkład normalny. Natomiast kurtoza dodatnia oznacza ***duże występowanie wartości ekstremalnych*** (szerokie wąsy).

```
> skewness(titanic$Age)
[1] 0.440751
> kurtosis(titanic$Age)
[1] 0.5735702
```

Z dotychczasowej analizy wynika, że rozkład zmiennej ***Age*** może przypominać rozkład normalny. Jednak aby to sprawdzić użyjemy testu ***Shapiro-Wilka***, który jest standardowym narzędziem wykorzystywanym do sprawdzenia normalności danych, ze względu na wyróżniającą go dużą moc.

Wynik (zmienna W) jest całkiem duży (>0.90) co mogłoby wskazywać na normalność rozkładu natomiast wartość parametru p jest dużo mniejsza od ustalonej wartości minimalnej (0.05), więc te ***dane nie charakteryzują się rozkładem normalnym.***

```
> shapiro.test(titanic$Age)

        Shapiro-Wilk normality test

data:  titanic$Age
W = 0.96965, p-value = 1.066e-11
```

Możemy zobaczyć to na histogramie obok, który trochę przypomina ale nie jest rozkładem normalnym.

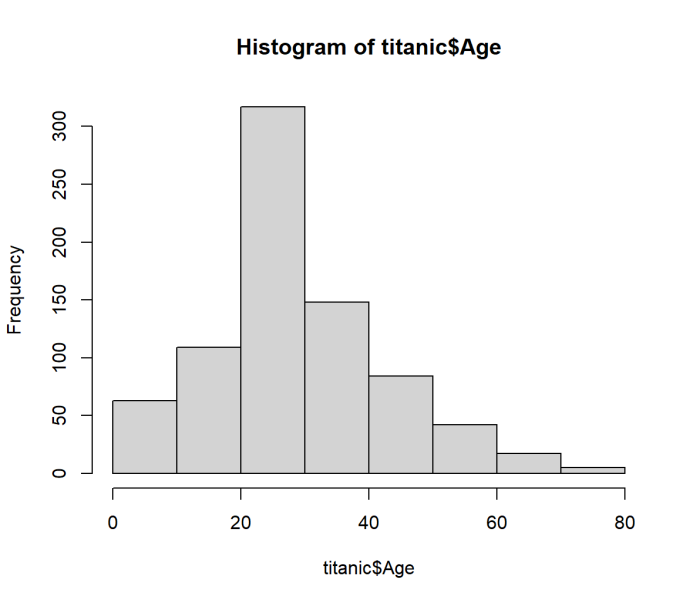

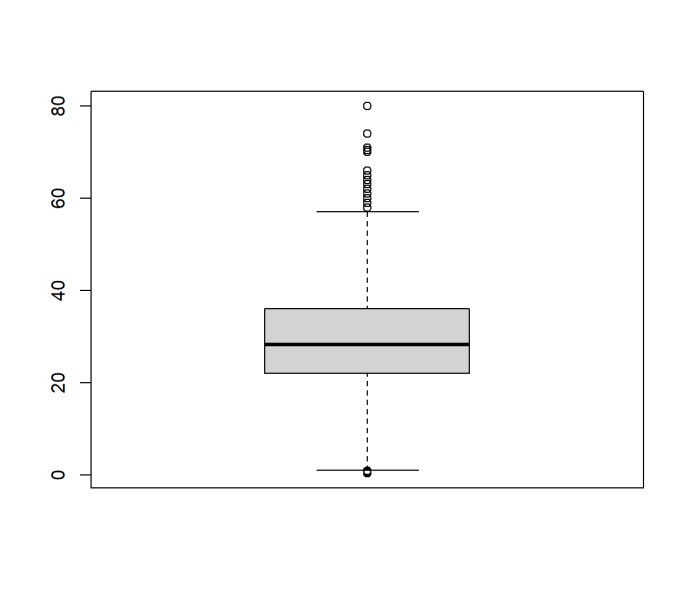

PODSUMOWANIE

Dane z pliku *titanic_new.csv* zawierają podstawowe informacje o pasażerach Titanica, który był najbardziej prestiżowym a zarazem największym statkiem swojego czasu. Dzięki niemu ***mogliśmy znaleźć bardzo ciekawe statystyki i wpływy zmiennych na śmiertelność***. Każda zależność dało się sensownie wytłumaczyć. Na przedstawionym obok wykresie korelacji możemy zauważyć wszystkie kolumny i korelacje między nimi. Wielkość kółek oznacza siłę natomiast kolor oznacza kierunek. Możemy zauważyć oczywiste ***połączenia między* Fare *i* Pclass*, czyli kosztem i klasą***, czy ***pomiędzy* Parch *i* SibSp*, czyli między ilością dzieci/rodziców a liczbą rodzeństwa/partnerów***. Jednak pojawia się też zauważalna korelacja, którą pokazałem w tym projekcie a mianowicie lekka ***relacja między klasą miejsca a śmiertelnością***. Uważam, więc że cel został spełniony.

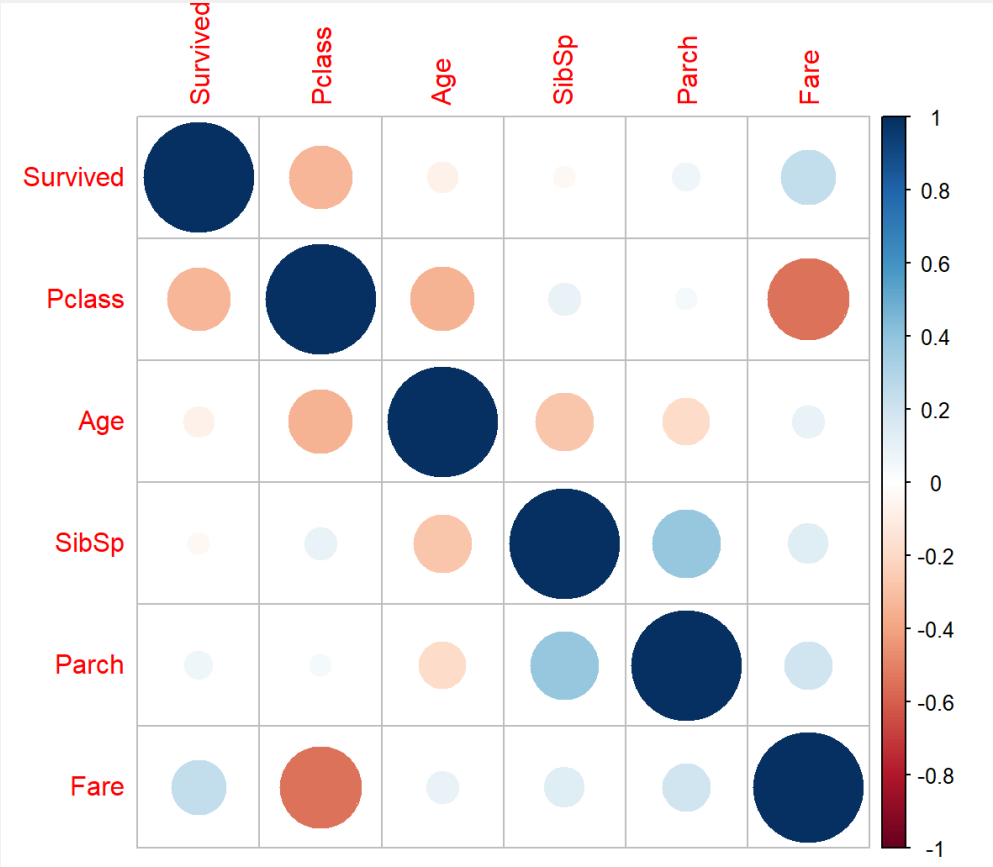

KOD

```
install.packages("tidyverse")
library(tidyverse)

titanic = read.csv('titanic_new.csv', header=TRUE, sep=',')
view(titanic)

# USUWANIE NIEPOTRZEBNYCH KOLUMN ==============================================
titanic = titanic %>% select(-Passenger.Id, -Ticket, -Name)
view(titanic)

# USUWANIE DULIKATÓW ==========================================
install.packages("dplyr")
library(dplyr)

nrow(titanic)
nrow(unique(titanic))
titanic = distinct(titanic)
view(titanic)

# BŁĘDNE TYPY ====================================================
install.packages("stringr")
library(stringr)

sapply( titanic, typeof )
titanic$Embarked[titanic$Embarked == ""] = as.numeric(titanic$Embarked)
titanic$Fare = str_replace_all(titanic$Fare, "'", "")
titanic$Fare = as.numeric(titanic$Fare)

```

```r
# ODSZUMIANIE ====================================================
unique(titanic$Survived)
titanic$Survived[titanic$Survived %in% c(-1, 111, 112)] = 1
unique(titanic$Pclass)
unique(titanic$Sex)
titanic$Sex[titanic$Sex %in% c("mal3e", "mal4e", "malle", "malwe")] = "male"
titanic$Sex[titanic$Sex %in% c("feemale", "f2emale")] = "female"
unique(titanic$Embarked)
titanic$Embarked[titanic$Embarked %in% "s"] = "S"

titanic$Age[titanic$Age < 0] = NA
titanic$Age[titanic$Age > 120] = NA
titanic$SibSp[titanic$SibSp < 0] = NA
titanic$Parch[titanic$Parch < 0] = NA

titanic = titanic %>% select(-Cabin)

install.packages("Hmisc")
library(Hmisc)

titanic$Age = impute(titanic$Age, median)
moda_embarked = names(sort(table(titanic$Embarked), decreasing = TRUE))[1]
titanic$Embarked[is.na(titanic$Embarked)] = moda_embarked

#ANALIZA DANYCH ==============================================
table(titanic$Survived)

titanic_cpy = titanic %>% select(Survived)
titanic_cpy = titanic_cpy[titanic_cpy$Survived == 0, ]
deth_procentile = length(titanic_cpy)/nrow(titanic)
deth_procentile * 100

```

```r
# ŚMIERTELNOŚĆ W ZALEŻNOŚCI OD PŁCI =========================
titanic_cpy = titanic %>% select(Survived, Sex)
titanic_cpy = titanic_cpy[titanic_cpy$Survived == 0, ]
death_sex = table(titanic_cpy$Sex)/table(titanic$Sex)
death_sex = death_sex * 100
# Wykres słupkowy
barplot(death_sex,
        names.arg = c("kobiety", "mężczyźni"),
        col = "green",
        main = "Śmiertelność pasażerów Titanica wg płci",
        xlab = "Śmiertelność (%)",
        xlim = c(0, 100), horiz = TRUE )

table(titanic$Sex)

# ŚMIERTELNOŚĆ W ZALEŻNOŚCI OD GRUPY WIEKOWEJ ===============
death_children = nrow(titanic[titanic$Age < 18 & titanic$Survived == 0,  ]) / nrow(titanic[titanic$Age < 18,  ])
death_children = death_children * 100
death_young_adult = nrow(titanic[titanic$Age >= 18 & titanic$Age < 30 & titanic$Survived == 0,  ]) / nrow(titanic[titanic$Age >= 18 & titanic$Age < 30,  ])
death_young_adult = death_young_adult * 100
death_adult = nrow(titanic[titanic$Age >= 30 & titanic$Age < 50 & titanic$Survived == 0,  ]) / nrow(titanic[titanic$Age >= 30 & titanic$Age < 50,  ])
death_adult = death_adult * 100
death_olders = nrow(titanic[titanic$Age >= 50 & titanic$Age < 120 & titanic$Survived == 0,  ]) / nrow(titanic[titanic$Age >= 50 & titanic$Age < 120,  ])
death_olders = death_olders * 100

# Dane i etykiety
death_rates <- c(death_children, death_young_adult, death_adult, death_olders)
age_groups <- c("Dzieci (<18)", "Młodzi dorośli (18-29)", "Dorośli (30-49)", "Starsze osoby (50+)")

# Wykres słupkowy
barplot(death_rates,
        names.arg = age_groups,
        col = "magenta",
        main = "Śmiertelność pasażerów Titanica wg grup wiekowych",
        ylab = "Śmiertelność (%)",
        ylim = c(0, 100) )
```

```r
# ŚMIERTELNOŚĆ W ZALEŻNOŚCI OD KLASY BILETU ====================
titanic_cpy = titanic %>% select(Survived, Pclass)
titanic_cpy = titanic_cpy[titanic_cpy$Survived == 0, ]
death_class = table(titanic_cpy$Pclass)/table(titanic$Pclass)
death_class = death_class * 100

# Wykres słupkowy
barplot(death_class,
        names.arg = c("1 klasa", "2 klasa", "3 klasa" ),
        col = "darkred",
        main = "Śmiertelność pasażerów Titanica wg klasy biletu",
        ylab = "Śmiertelność (%)",
        ylim = c(0, 100) )

table(titanic$Pclass)


# ANALIZA I STATYSTYKI KOLUMNY Z WIEKEM PASAŻERÓW ==============
summary(titanic$Age)

install.packages("e1071")
library(e1071)

var(titanic$Age)
IQR(titanic$Age)
sd(titanic$Age)
max(titanic$Age) - min(titanic$Age)

hist(titanic$Age)
boxplot(titanic$Age)

skewness(titanic$Age)
kurtosis(titanic$Age)
shapiro.test(titanic$Age)

install.packages("corrplot")
library(corrplot)
titanic_cor = cor(titanic[, sapply(titanic, is.numeric)], use = "complete.obs")
corrplot(titanic_cor)

```